SÜLEYMAN DEMİREL ÜNİVERSİTESİ

Bilgisayar Mühendisliği · Tasarım I

Siber Güvenlik Alanına Özel Dil Modeli İçin Veri Seti Hazırlama

Vize Çalışması

Domain Corpus · Instruction Dataset · Veri Kalitesi

10 Kasım 2026

1. Problem, amaç ve kapsam

Başlık	Çalışma tanımı
Problem	Siber güvenlikteki teknik bilgilerin çok sayıda rapor, standart, makale ve kitapta dağınık bulunması.
Hedef	Alana özel bir dil modelinin uyarlanmasında kullanılacak Domain Corpus ve Instruction veri setlerini hazırlamak.
Kapsam	Ağ/sistem/web/mobil/bulut güvenliği, kimlik doğrulama, kriptografi, zararlı yazılım, olay müdahalesi, adli bilişim, DevSecOps.
Kullanım	Teknik soruları yanıtlayan, alan terimlerini anlayan ve kaynakla ilişkilendirilebilen bir sistemin veri temeli.
Vize odağı	Veri toplama, metin çıkarma, temizleme, tekrarlama denetimi, bölme, soru-cevap üretimi ve kalite kontrolü.

2. Veri kaynakları: belge türlerine göre dağılım

Corpus içindeki 731 kaynak belgenin PDF adı ve kapak bilgisine dayalı ön sınıflandırması

Kaynak grubu / belge türü	Belge	İçerik örneği
NIST teknik yayınları (aday)	108	SP 800 serisi, bilgi güvenliği kılavuzları
OWASP dokümanları (aday)	5	ASVS, uygulama güvenliği
ENISA yayınları (aday)	5	Tehdit görünümü ve güvenlik raporları
Akademik araştırma makaleleri	353	Güvenlik yöntemleri ve deneysel çalışmalar
Akademik slaytlar / ders sunumları	2	Ethical Hacking, Siber Güvenlik 101
Teknik kitaplar ve el kitapları	18	Android Hacker’s Handbook, The Hacker Playbook 3
Diğer teknik yayınlar / türü ayrılmayan	240	Çeşitli güvenlik belgeleri ve teknik metinler
TOPLAM	**731**	**9.554 metin parçasının kaynak havuzu**

Akademik slayt ve teknik kitap sayıları, başlığından/kapak örneğinden bu türde olduğu belirlenebilen seçilmiş dosyalardır.

3. Kaynak tablosu: adres, tür, dil ve lisans

Belgeler PDF adları / ilk sayfalara göre gruplandı; adresler kurumsal katalog veya yerel envanter referansıdır.

Kaynak grubu	Adet	Erişim / katalog adresi	Tür	Dil*	Lisans / erişim
NIST yayınları (aday)	108	csrc.nist.gov/Publications	PDF	EN	Belge bazlı kontrol
OWASP dokümanları (aday)	5	owasp.org/projects/asvs	PDF	EN	ASVS: CC BY-SA 4.0**
ENISA yayınları (aday)	5	enisa.europa.eu/publications	PDF	EN	Belge bazlı kontrol
Akademik makaleler	353	Belgeye özgü atıf / DOI	PDF	EN ağ.	Yayın bazlı kontrol
Akademik slaytlar	2	Ders materyali / yerel PDF	PDF	TR + EN	Yayıncıya göre
Teknik kitaplar	18	Kitap başlığı / yerel PDF	PDF	EN ağ.	Yayıncıya göre
Diğer teknik yayınlar	240	Yerel PDF envanteri	PDF	Karışık	Belge bazlı kontrol
TOPLAM	**731**	**Corpus kaynak belgeleri**	**PDF**	**—**	**Belgeye göre**

İlk sayfa dil taraması EN adayı: 580 TR adayı: 4 Belirsiz: 147

** Dil adayları kesin belge dili değildir. ** OWASP ASVS proje lisansı. Envanter tarihi: 09.11.2026.*

4. Akademik slaytlar ve teknik kitaplar: gerçek örnekler

Kaynak dosyası / başlık	Belge türü	Sayfa
Introduction to Ethical Hacking (001Introduction...)	Ders sunumu	17
Siber Güvenlik 101 — FinTech 101 (Nisan 2019)	Ders sunumu	63
Android Hacker’s Handbook	Teknik kitap	577
The Hacker Playbook 3 — Practical Guide to Penetration Testing	Teknik kitap	264
Violent Python — A Cookbook for Hackers...	Teknik kitap	270
Bug Bounty Field Manual	Teknik el kitabı	72

Bu belge türleri, resmî standartlarla birlikte hem kavramsal açıklama hem de uygulamaya dönük güvenlik terminolojisi sağlamaktadır.

5. Veri hazırlama hattı ve aşama çıktıları

Aşama	Uygulama	Ölçülen çıktı
1. Ham PDF havuzu	data/raw altındaki PDF dosyaları	1.283 PDF
2. PDF açılabilirliği	PDF envanter taraması	1.282 açıldı; 1 hata
3. Extraction çıktıları	data/extracted kaynak dosya adları	1.231 TXT anahtarı
4. Cleaning çıktıları	data/cleaned_v2 kaynak dosya adları	1.230 TXT anahtarı
5. Domain Corpus	731 kaynak belgeyi filtreleme / parçalama	9.554 chunk
6. Instruction üretimi	562 kaynak belgeden soru-cevap üretimi	3.075 soru-cevap
7. SFT biçimi	messages: user / assistant	3.075 / 3.075 ayrıştırıldı
8. Kalite ön kontrolü	180 soru; 12 kritik aday karantinada	3.063 geçici SFT adayı

Aşamalardaki sayılar farklı dosya kümelerini/ölçü birimlerini gösterir; doğrudan eleme yüzdesi olarak okunmamalıdır.

6. Metin çıkarma ve temizleme örnekleri (1/3)

Aynı kaynak dosyanın extracted / cleaned_v2 başlangıç kesitleri; paragraflar bire bir hizalanmamıştır.

Önce — extracted	Sonra — cleaned_v2
01 · Approve What_ Exactly_ Effect Binding and Trusted Rendering	
PREPRINT Approve What, Exactly? Approve What, Exactly? Effect Binding and Trusted Rendering for Agent Step-Up Authorization Sai Varun Kodathala SportsVision AI ...	Approve What, Exactly? Approve What, Exactly? Effect Binding and Trusted Rendering for Agent Step-Up Authorization Prashanth Pollishetty AI agents now pause for ...
02 · SPIDES_ Information-Flow Control for Browser Agents	
SPIDES: INFORMATION-FLOW CONTROL FOR BROWSER AGENTS Egor Zverev ∗† ISTA Juhee Kim ∗ Microsoft Leon Trampert† CISPA Helmholtz Center for Information Security Boris ...	CISPA Helmholtz Center for Information Security Santiago Zanella-Béguelin Browser agents automate complex workflows by reading and acting on arbitrary page ...
03 · Google.Hacking.for.Penetration.Testers.Volume2	
w w w. s y n g re s s . c o m Syngress is committed to publishing high-quality books for IT Professionals and deliv- ering those books in media and formats that ...	w w w. s y n g re s s . c o m Syngress is committed to publishing high-quality books for IT Professionals and deliv- ering those books in media and formats that ...
04 · ENISA_Technical_implementation_guidance_on_cybersecurity_r...	
EUROPEAN UNION AGENCY FOR CYBERSECURITY TECHNICAL IMPLEMENTATION GUIDANCE On Commission Implementing Regulation (EU) 2024/2690 of 17 October 2024 laying down ...	On Commission Implementing Regulation (EU) 2024/2690 of 17 October 2024 laying down rules for the application of NIS2 Directive as regards technical and ...

Kaynak: reports/corpus/VIZE_TOKEN_VE_ONCE_SONRA_RAPORU.txt · Toplam 12 gerçek eşleşme; e-posta adresleri gizlenmiştir.

6. Metin çıkarma ve temizleme örnekleri (2/3)

Aynı kaynak dosyanın extracted / cleaned_v2 başlangıç kesitleri; paragraflar bire bir hizalanmamıştır.

Önce — extracted	Sonra — cleaned_v2
05 · Black Hat Python, 2nd Edition	
CONTENTS IN DETAIL PRAISE FOR THE FIRST EDITION TITLE PAGE COPYRIGHT DEDICATION ABOUT THE AUTHORS FOREWORD PREFACE ACKNOWLEDGMENTS CHAPTER 1: SETTING UP YOUR ...	Installing Kali Linux Python Networking in a Paragraph Building a TCP Proxy Building a UDP Host Discovery Tool Packet Sniffing on Windows and Linux Decoding the ...
06 · sec_2510.03610v1_PentestMCP__A_Toolkit_for_Agentic_P	
PentestMCP: A Toolkit for Agentic Penetration Testing Zachary Ezetta Wu-chang Feng [e-posta] [e-posta] Portland State University Department of Computer Science ...	PentestMCP: A Toolkit for Agentic Penetration Testing Portland State University Department of Computer Science Agentic AI is transforming security by automating ...
07 · ByteMark_ A Unified Byte-Level Watermark for Detection Acros	
ByteMark: A Unified Byte-Level Watermark for Detection Across Language Models Xiaopu Wang [e-posta] Runze Li [e-posta] Abstract As watermarking of LLM-generated ...	ByteMark: A Unified Byte-Level Watermark for Detection Across Language Models As watermarking of LLM-generated text enters deployment, users increasingly need to ...
08 · Provenance and Authorization in Autobiographical Language Mo	
Provenance and Authorization in Autobiographical Language Models A Security Model and Synthetic Memory Study Faruk Alpay1 ∗ Taylan Alpay2 1Department of Computer ...	Provenance and Authorization in Autobiographical Language Models A Security Model and Synthetic Memory Study 1Department of Computer Engineering, Bahçeşehir ...

Kaynak: reports/corpus/VIZE_TOKEN_VE_ONCE_SONRA_RAPORU.txt · Toplam 12 gerçek eşleşme; e-posta adresleri gizlenmiştir.

6. Metin çıkarma ve temizleme örnekleri (3/3)

Aynı kaynak dosyanın extracted / cleaned_v2 başlangıç kesitleri; paragraflar bire bir hizalanmamıştır.

Önce — extracted	Sonra — cleaned_v2
09 · NIST.SP.800-163r1	
NIST Special Publication 800-163 Revision 1 Vetting the Security of Mobile Applications Michael Ogata Josh Franklin Jeffrey Voas Vincent Sritapan Stephen ...	NIST Special Publication 800-163 Vetting the Security of This publication is available free of charge from: C O M P U T E R S E C U R I T Y NIST Special ...
10 · Communication-Efficient Private Federated Reinforcement Lear	
Communication-Efficient Private Federated Reinforcement Learning with Post-Quantum Authentication for Vehicular Networks Hojat Allah Salehi1,2, Devrim Aras1,2, ...	Communication-Efficient Private Federated Reinforcement Learning with Post-Quantum Authentication for Hojat Allah Salehi1,2, Devrim Aras1,2, Md Jueal Mia1,2, M. ...
11 · Control Baselines for Information Systems and Organizations	
NIST Special Publication 800-53B Control Baselines for Information Systems and Organizations JOINT TASK FORCE This publication is available free of charge from: ...	NIST Special Publication 800-53B Control Baselines for Information Systems and Organizations This publication is available free of charge from: NIST Special ...
12 · Security and robustness analysis of encrypted communications	
International Journal of Network Security & Its Applications (IJNSA) Vol.18, No.4/5, September 2026 DOI: 10.5121/ijnsa.2026.18502 15 SECURITY AND ROBUSTNESS ...	International Journal of Network Security & Its Applications (IJNSA) Vol.18, No.4/5, September 2026 DOI: 10.5121/ijnsa.2026.18502 15 Carlos Roberto ...

Kaynak: reports/corpus/VIZE_TOKEN_VE_ONCE_SONRA_RAPORU.txt · Toplam 12 gerçek eşleşme; e-posta adresleri gizlenmiştir.

7. Ön işleme kararları ve metadata

İşlem	Amaç / kayıt biçimi
PDF metin çıkarma	PyMuPDF ile metin katmanını okumak; tablo ve çok sütunlu içerikleri gözden geçirmek.
Temizleme / normalizasyon	Boşluk, satır kırılması, sayfa artığı ve Unicode kaynaklı bozulmaları azaltmak.
Parçalama (chunking)	Uzun dokümanları model için işlenebilir metin kesitlerine ayırmak.
Kalite bayrakları	Çok kısa parça, kaynakça, noktalı içindekiler, Unicode bozulması vb. durumları işaretlemek.
Metadata	id, document_id, source_document, text, char_count, word_count, split, quality_flags.
Veri biçimi	Her satırın bağımsız JSON nesnesi olduğu JSONL kullanımı.

8. Birebir tekrar, yakın tekrar ve veri sızıntısı kontrolü

Kontrol	Yöntem / ölçüm	Sonuç
Birebir tekrar	Metinlerin SHA-256 özeti	0 aynı metin parçası
İlk yakın tekrar taraması	TF-IDF cosine ≥ 0,83	65 aday çift
Yüksek benzerlik	TF-IDF cosine ≥ 0,92	16 aday çift
Ayrıntılı aday eşleştirme	Sonraki yakın tekrar taraması	63 aday çift
Önceki farklı bölme eşleşmesi	Tespit edilen 63 çift için	20 çift
Yeni farklı bölme eşleşmesi	İlişkili kaynakları birlikte ayırma	0 çift
Kayıt korunumu	Yeniden bölümlemede içerik/ID kontrolü	Kayıp kayıt: 0

Benzerlik adayları doğrudan silinmedi; tespit edilen bağlantılı kaynaklar aynı train/val/test bölümüne taşındı.

9. Domain Corpus: nicel istatistikler

Metrik	Sonuç
Corpus kaynak belgesi	731
Metin parçası (chunk)	9.554
Toplam karakter	27.440.087
Toplam kelime (boşluk ayırma)	3.988.017
Ortalama chunk uzunluğu	2.872 karakter
Medyan chunk uzunluğu	2.910 karakter
Otomatik bayrak taşımayan parça	9.308 (%97,43)
Kalite bayrağı bulunan parça	246 (%2,57)

Token ölçümü Qwen3-4B-Base tokenizer ile bir sonraki tabloda ayrıntılandırılmıştır.

9a. Corpus: gerçek token istatistikleri

Qwen/Qwen3-4B-Base tokenizer · add_special_tokens=False · 9.554 chunk / 731 belge

Chunk başına token dağılımı

Ölçüm	Token
Toplam token	5.866.093
Minimum	55
Medyan	573
Ortalama	614
%95. yüzdelik (P95)	948
Maksimum	10.712
Belge başına ortalama	8.024,8

Train / validation / test token miktarları

Bölüm	Token
Train	4.731.185
Validation	622.499
Test	512.409
TOPLAM	**5.866.093**

Her Corpus kaydının text alanı tokenizer ile sayılıp toplandı; eğitilmiş modelin çıktısı değil, gerçek tokenizer ölçümüdür.

10. Kaynak bazlı train / validation / test ayrımı

Domain Corpus

Bölüm	Chunk	Kaynak belge	Oran
Train	7.643	587	%80,00
Validation	1.059	77	%11,08
Test	852	67	%8,92
Toplam	**9.554**	**731**	**%100**

Instruction / SFT

Bölüm	Soru–cevap	Kaynak belge	Oran
Train	2.418	449	%78,63
Validation	359	60	%11,67
Test	298	53	%9,69
Toplam	**3.075**	**562**	**%100**

11. Domain Corpus ve Instruction kayıt formatları

Domain Corpus alanları

id · document_id · source_document · source_path_original · text · char_count · word_count · split · quality_flags

Instruction / SFT alanları

source_document · topic · id → messages: [{role: "user", content: "Soru"}, {role: "assistant", content: "Cevap"}]

SFT dönüştürme denetimi: 3.075/3.075 soru-cevap ayrıştırıldı; orijinal veri korunarak ayrı JSONL dosyaları yazıldı.

12. Instruction veri seti: 12 konuya göre dağılım

Konu	Soru	Oran	Konu	Soru	Oran
Authentication	624	%20,29	Web Security	212	%6,89
Network Security	343	%11,15	Cloud Security	188	%6,11
System Security	323	%10,50	Cryptography	165	%5,37
Penetration Testing	316	%10,28	Mobile Security	139	%4,52
Incident Response	315	%10,24	DevSecOps	129	%4,20
Malware	246	%8,00	Digital Forensics	75	%2,44

TOPLAM: 3.075 soru-cevap · 562 kaynak belge

13. Instruction görev türleri: soru biçimi analizi

3.075 sorunun soru kalıplarıyla yapılan kural tabanlı ön sınıflandırması

Görev türü (otomatik grup)	Soru	Oran
Kavram / açıklama kalıbı	1.208	%39,3
Diğer doğrudan bilgi sorgulama	1.144	%37,2
Sayısal bilgi / tarih sorgulama	407	%13,2
Yöntem / süreç sorgulama	150	%4,9
Karşılaştırma sorgusu	88	%2,9
Neden-sonuç sorgusu	78	%2,5
TOPLAM	**3.075**	**%100**

Görev türleri metin kalıplarından türetilmiştir; veri setindeki asıl 12 “topic” etiketiyle karıştırılmamalıdır.

14. Veri setinden üç gerçek instruction örneği

Konu / kaynak	Instruction (soru)	Response (cevap)
Web Security Self-Evolving Static Analysis	What distinguishes the safe and vulnerable SQL injection patterns (a) and (b)?	Safe (b) binds bar using a parameterized query; vulnerable (a) concatenates bar into the SQL string.
DevSecOps NIST SP 800-218	What is the recommended practice for minimizing direct human access to toolchain systems, such as build services?	Minimize direct access and continuously monitor and audit access attempts and toolchain-system use.
Authentication ARCADE (DAC/RBAC)	What is the potential issue when administrators grant more access than necessary in DAC/RBAC models?	Excessive permissions violate the principle of least privilege.

Üç örnek, 3.075 kayıtlık gerçek QA veri setinden seçilmiştir; soru ve cevaplar slayta sığması için kısaltılmıştır.

15. Domain Corpus kalite kontrolü: otomatik bayraklar

Kontrol / kalite işareti	Metin parçası
İçindekiler / noktalı sayfa dizini olasılığı	158
Düşük alfabetik karakter oranı	130
Kaynakça / referans ağırlıklı içerik	14
Yakın tekrar adayıyla ilişkili	32
Kısa metin parçası	8
Sayfa geçişi artığı olasılığı	7
Bozuk Unicode karakteri	2
En az bir bayrak taşıyan toplam	**246**

Bir metin parçası birden fazla kalite işareti taşıyabilir; satırların toplamı 246'dan farklıdır.

16. Instruction veri kalitesi: 180 soruluk ön inceleme

Ön inceleme sınıfı	Soru	Sonuç / uygulama
İlk taramada belirgin hata bulunmayan	56	İlk kontrol etiketi
Ek kontrol gerektiren	36	Kaynak, konu ve güncellik kontrolü
Konu etiketi düzeltme adayı	33	Konu uyumu incelemesi
Teknik kapsam dışı adayı	25	Alan filtresi incelemesi
Cevap düzeltme adayı	18	Kaynağa göre düzeltme önerileri
Ciddi hata / karantina adayı	12	Geçici olarak ayrı tutuldu
TOPLAM	**180**	**12 konu × 15 soru · 179 kaynak belge**

Kendi incelemem · 180/180 soru

180 sorunun tamamını çeviri desteğiyle inceledim. 108 ön onay, 11 düzeltme, 60 çıkarma ve 1 kaynak inceleme kararı verdim.
Üstteki tablo modelin ilk taraması. Kendi ön kararlarımı Excel’e kaydettim ve ana veri setine henüz uygulamadım.
Teknik doğrulama için orijinal PDF’lerle karşılaştırma gerekiyor.

17. Kod ve veri seti teslim yapısı

Bileşen	Projedeki çıktılar
Ham veri	data/raw/ — PDF dokümanları
Ara metinler	data/extracted/ ve temizleme ara çıktıları
Corpus	data/final/guvenli_split_aday/corpus/ — train, val, test JSONL
Instruction	data/final/guvenli_split_aday/instruction/ — train, val, test JSONL
SFT	data/final/sft_aday/ — messages biçiminde JSONL
Kalite çalışması	reports/corpus/ ve reports/instruction/ — denetimler, envanterler
Dokümantasyon	README.md, DATASET_CARD.md, INSTRUCTION_CARD.md
Betikler ve sürüm	scripts/ — extraction, cleaning, split, istatistik, kalite kontrol

GitHub (özel depo): github.com/senaao/Tasarim1_SiberGuvenlik_MVP | main: b01a1a8 | Ham PDF/JSONL yerelde tutulur.

18. Karşılaşılan teknik durumlar ve çözümler

Teknik durum	Uyguladığım yaklaşım / elde edilen sonuç
Farklı PDF sayfa düzenleri	PyMuPDF ile metin çıkarımı; dosya bazlı envanter ve hata takibi.
Dağınık teknik kaynaklar	Kaynak dosya adlarını Corpus kimlikleriyle eşleştirme; 731 belge envanteri.
Benzer metinlerin farklı bölmelere düşmesi	63 aday çift üzerinden kaynakları birlikte bölümleme; saptanan çapraz çift: 0.
LLM üretimli cevaplarda bilgi karışması	180 örneklik kaynak temelli ön inceleme; 12 ciddi adayın ayrılması.
Alan dışı veya etiket kayması olan sorular	Konu ve kapsam adaylarını ayrı işaretleme; düzeltme önerilerini raporlama.
Büyük veri setini sürümleme	Ham veriyi koruma, ara dosyaları ayırma, JSONL ve kontrol raporları kullanma.

19. Sonuç ve final dönemine geçiş

Vizede hazırladığım çıktı	Miktar / kullanım
Domain Corpus v1.0 aday verisi	731 kaynaktan 9.554 metin parçası
Instruction Dataset v1.0 aday verisi	562 kaynaktan 3.075 soru-cevap
SFT biçim dönüşümü	3.075 kayıt; karantina sonrası 3.063 geçici aday
Veri bölme ve kontrolleri	Kaynak bazlı train/validation/test; 63 benzer çift kontrolü
Kalite değerlendirmesi	180 soru model destekli ön tarama; Corpus kalite işaretleri
	180/180 soru için çeviri destekli kendi ön kararlarım
Belgelendirme / GitHub	Güncel veri kartları, raporlar ve Python kodları · main: b01a1a8

Final dönemi yol haritası

Domain Corpus → CPT / DAPT | Instruction → SFT | Karşılaştırmalı ölçüm → RAG / API / arayüz